AutoSystemDesign

От бизнес-требований к проверяемой модели архитектуры микросервисной системы

Дичковский Владимир

Какую задачу решает инструмент

Проблема

- В BRD описаны функции и ограничения, а не компоненты.
- Архитектор вручную переводит требования в схемы.
- Согласованность C4, сценариев и API приходится проверять.

Подход

- LLM предлагает структурированную модель.
- Доменный код проверяет её правилами.
- Из одной модели строятся связанные артефакты.

Это первая архитектурная гипотеза для ревью, а не автоматическое утверждение проекта.

Вход: один BRD заказчика

Демонстрационный фрагмент BRD интернет-магазина

Функциональные требования

- Корзина и подтверждение заказа.
- Проверка остатков и расчёт цены.
- Оплата, создание заказа, уведомление.
- Просмотр статуса заказа покупателем.

Нефункциональные требования

- Обычно: 120 запросов/с
- В пике: 400 запросов/с
- p95 не выше 300 мс
- Доступность: 99,9%

BRD — исходные бизнес-формулировки. Состав сервисов пока не задан.

Результат извлечения: требования

Наглядный пример структурирования BRD; это не лог конкретного запуска LLM

Функциональные

- FR-01: оформление заказа
- FR-02: проверка наличия товаров
- FR-03: оплата и подтверждение
- FR-04: просмотр статуса

Нефункциональные

- Нагрузка: 120 / 400 RPS
- Целевое p95: 300 мс
- Доступность: 99,9%

След происхождения: для каждого значения сохраняется цитата BRD; конфликтующие формулировки фиксируются отдельно.

Извлечение не означает безусловного доверия LLM

Двухэтапная проверка

1. LLM выделяет требование и цитату.
2. Код сверяет цитату с BRD.
3. LLM сопоставляет подтверждённое требование с полями модели.
4. Значения ещё раз проверяются по источнику.

Сомнительные данные

- Неподтверждённые числа исключаются.
- Противоречия сохраняются для человека.
- Отсутствующие данные не придумываются.

Пример неоднозначности BRD: доставка письма за 10 секунд или до 2 минут в пике? Решение нужно уточнить.

Архитектура конвейера и зависимости этапов



Performance зависит от C4; API опирается на C4 и Sequence.

Как LLM превращается в проверяемый генератор

Генерация

- LiteLLM: единая точка работы с моделями.
- LLM возвращает структурированный ответ.
- Pydantic преобразует его в типизированную доменную модель.
- Код PlantUML строит отдельный рендерер, не сама LLM.

Если нарушены правила

- Ошибки разбора и доменной проверки возвращаются модели.
- Модель исправляет ответ.
- Число попыток ограничено.

Принцип: генеративная модель предлагает, детерминированные валидаторы принимают или отклоняют.

C4: не картинка, а модель предметной области

Типы компонентов

- Клиент, балансировщик
- Вычислительный сервис
- База данных и кэш
- Брокер сообщений

Параметры модели

- Реплики и лимит параллелизма
- Время обработки и разброс
- Размер очереди и стоимость
- Протокол и тип маршрутизации связи

Зачем: одна и та же модель нужна и для рисования диаграммы, и для расчёта нагрузки и правил валидации.

Валидаторы C4: три уровня проверки

Структура

Уникальные ID, допустимые связи, отсутствие циклов

Семантика

Поставщик и потребитель брокера, путь мимо кэша

Расчёты

Поток RPS, пропускная способность, насыщение

Допустимо

Клиент → API → БД

Недопустимо

Клиент → БД напрямую

Онтология допустимых связей ограничивает пространство решений, которые может предложить LLM.

Пример: диаграмма компонентов C4

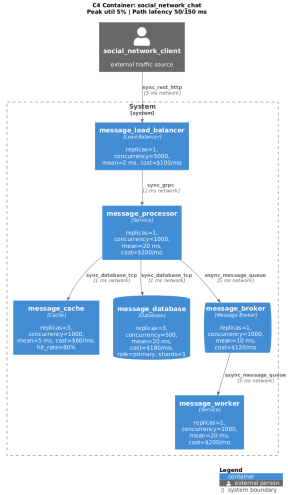


Иллюстрация из репозитория. Позже будет заменена результатом единого BRD-прогона.

Связи: протокол влияет на смысл графа

Контракт связи

- HTTP, gRPC, TCP или очередь сообщений
- Синхронный или асинхронный обмен
- Альтернативный маршрут либо fan-out

Почему это важно

- Разные пути по-разному получают RPS.
- Асинхронные ветви не добавляются к задержке клиентского ответа.
- Очередь и кэш меняют путь обработки.

Это модель обмена и распределения трафика, а не просто подписи на стрелках.

Sequence: от функционального требования к сценарию

Построение

- Каталог бизнес-ролей.
- Сценарий взаимодействия на каждое функциональное требование.
- Участники ссылаются на компоненты C4.

Проверка

- Существующие участники и связи.
- Согласованность ролей и клиента.
- Асинхронность уведомлений и событий.

Последовательность объясняет поведение архитектуры, которое не видно на статической C4.

Пример: диаграмма последовательностей

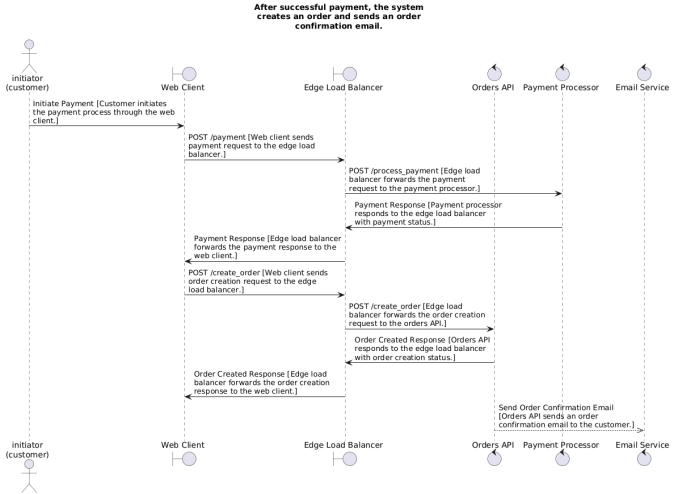


Иллюстрация из репозитория; связь с выбранным BRD ещё будет проверена на едином прогоне.

REST API: контракт строится после C4 и Sequence

Что генерируется

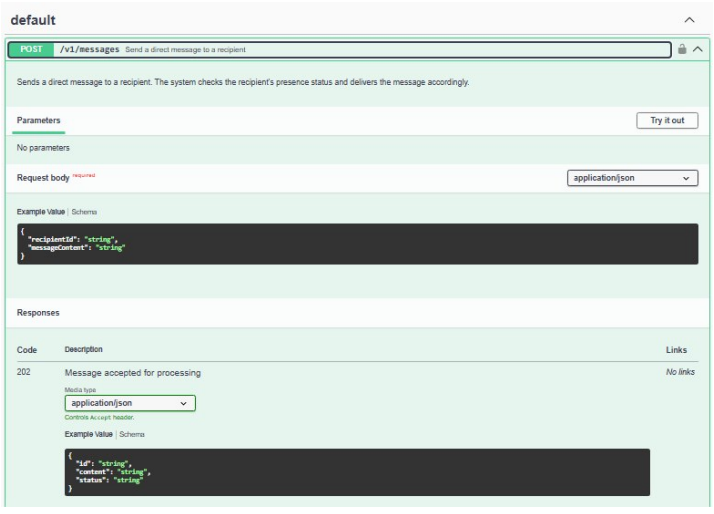
- Операции, методы и маршруты
- Параметры, запросы и ответы
- Связь операций с требованиями и компонентами

Что проверяется

- Уникальность операций
- Отсутствие коллизий маршрутов
- Согласованность ссылок и схем

OpenAPI описывает машинный контракт. Swagger UI делает его удобным для просмотра людьми.

Пример: Swagger UI



Существующий скриншот. Для финальной демонстрации нужен Swagger от того же BRD.

Пример: фрагмент OpenAPI JSON

Сокращённый иллюстративный контракт для оформления заказа, не фактический файл генерации

```
{
  "openapi": "3.1.0",
  "info": {
    "title": "Checkout API",
    "version": "1.0.0"
  },
  "paths": {
    "/orders": {
      "post": {
        "operationId": "createOrder",
        "summary": "Create a customer order",
        "responses": {
          "201": { "description": "Order created" },
          "409": { "description": "Item out of stock" }
        }
      }
    }
  }
}
```

В реальной демонстрации этот слайд заменяется фрагментом сгенерированного документа.

Анализ производительности: что считаем

Математическая часть

- Распределение RPS по путям графа.
- Пропускная способность и загрузка узлов.
- Оценка ожидания в очередях и средних задержек.

Условия применимости

- M/M/1, M/M/c и G/G/c: модели с допущениями.
- Число обслуживающих каналов не равно автоматически лимиту параллелизма.
- Неизвестная величина остаётся неизвестной.

Это аналитическая оценка модели, не нагрузочный тест и не моделирование реального кластера.

Пример: отчёт анализа производительности

checkout_baseline

Скриншот PDF-отчёта

32,10 мс: оценка средней задержки пути

Пример

60 RPS

нагрузка узлов

32,10 мс

максимальная оценка средней задержки пути

Реальный отчёт checkout_baseline из предоставленного PDF; исходный BRD демонстрационного примера отличается.

Почему среднее время не доказывает p95

В отчёте есть

- Средняя оценка ответа и ожидания.
- Загрузка и пропускная способность.
- Синхронный путь с наибольшей суммой средних задержек.

Отчёт не доказывает

- Соблюдение p95 или p99 по одному среднему.
- Поведение на реальной инфраструктуре.
- Потери при ограниченных очередях без модели.

Пример: среднее 32,10 мс не означает, что p95 не превысит 300 мс.

Разделение ответственности внутри системы

Domain

Типизированные модели, инварианты, расчёты

Application

Сервисы и стадии конвейера

Infrastructure

LLM, PlantUML, Swagger, PDF

- Замена модели LLM не должна переписывать доменные правила.
- Исходники PlantUML, граф и артефакты API хранятся отдельно.
- Рендеринг диаграмм поддерживает PlantUML и Kroki.

Результат описывается моделью, а не зависит от конкретного формата изображения.

Текущие возможности и границы

Реализовано

- Извлечение требований из BRD с цитатами и проверками.
- C4, Sequence, OpenAPI и Swagger.
- Расчётный JSON-отчёт и PDF-представление.
- Консольный запуск конвейера.

Следующие задачи

- Один воспроизводимый BRD-прогон для всех демонстрационных артефактов.
- Удобный интерфейс загрузки BRD и просмотра результатов.
- Развитие проверок и независимая оценка точности.

Автоматическая генерация — начало проектирования. Окончательное решение остаётся за архитектором.