Инструмент автоматизации проектирования

архитектуры микросервисных систем

AutoSystemDesign

Дичковский Владимир

Возможности инструмента

Построение архитектуры

- Формирование архитектурной модели по функциональным и нефункциональным требованиям.
- Генерация диаграмм компонентов и последовательностей.
- Формирование спецификации API.

Проверка и анализ

- Проверка структуры и связей архитектурной модели.
- Расчётная оценка нагрузки и задержек.
- Извлечение требований из документа с цитатами, подтверждающими исходный текст.

Результаты формируются в виде архитектурных моделей и связанных с ними артефактов.

Входные данные и результаты

Пользователь передаёт на вход:

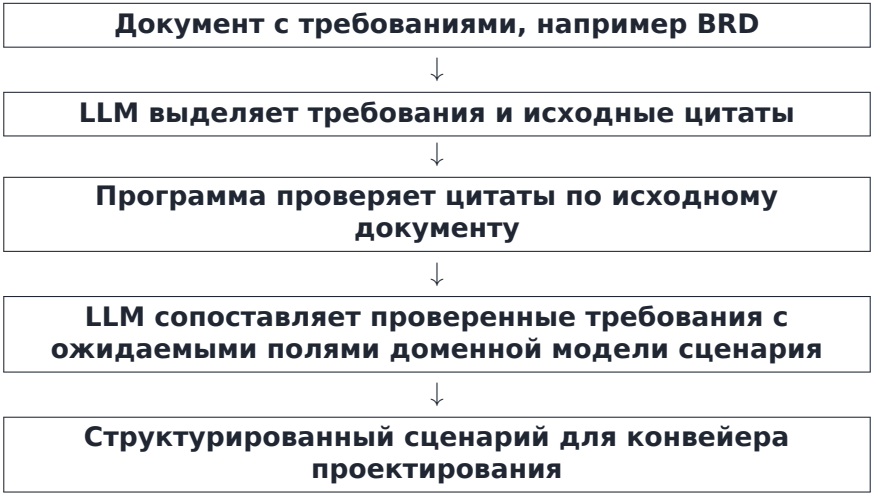
- BRD (документ бизнес-требований)
- Функциональные требования
- Нефункциональные требования
- Профиль нагрузки

Пользователь получает на выход:

- C4 Component Diagram
- Sequence-диаграмма на каждое функциональное требование
- OpenAPI 3.1 и Swagger UI

Вход можно задать в YAML или передать документ BRD: требования из документа извлекаются автоматически.

Извлечение требований из документа



Проверка достоверности извлечённых данных

Правила проверки

- Каждая цитата должна присутствовать в исходном тексте.
- Значения полей сценария сопровождаются проверенными цитатами.
- Числа должны буквально встречаться в цитате: пересчёт единиц не выполняется.

Если подтверждения нет

- Неподтверждённые утверждения и значения исключаются с указанием причины.
- Неоднозначности и противоречия сохраняются для проверки человеком.

Для извлечённых значений сохраняются исходные цитаты и результаты проверки.

Выходные артефакты

Диаграмма компонентов

- Скомпилированное изображение в выбранном формате (PNG/JPG)
- Исходный код PlantUML
- JSON доменной модели архитектуры компонентов

Диаграмма последовательностей

- Скомпилированное изображение в выбранном формате (PNG/JPG)
- Исходный код PlantUML
- JSON доменной модели диаграммы последовательно-стей

Спецификация API

- Спецификация OpenAPI в формате JSON
- Swagger UI в формате HTML

Изображения предназначены для просмотра, PlantUML — для редактирования диаграмм, JSON — для повторного использования структурированных моделей.

Варианты сервера рендеринга PlantUML

Для компиляции исходного кода PlantUML в изображение доступны три варианта:

1. **Локальный сервер PlantUML, развёртываемый через Docker Compose**
   Развёртывается вместе с проектом; конфигурация включена в репозиторий.
2. **Официальный сервер PlantUML**
   Используется размещённый разработчиками PlantUML сервер.
3. **Kroki**
   Универсальный сервис рендеринга диаграмм, поддерживающий PlantUML и другие форматы.

Пример входного YAML

Структура сценария

```yaml
project_name: "social_network_chat"
description: "Messaging module"
workload:
  baseline_requests_per_second: 500.0
  peak_requests_per_second: 2500.0
  read_ratio: 0.6
requirements:
  - type_identifier: latency
    threshold_value: 150.0
    percentile: 99.0
functional_requirements:
  - identifier: "req_msg_01"
    name: "Direct Message Delivery"
    text: >
      Sender sends a message to a recipient.
```

Генерация и проверка



Ключевые принципы

- LiteLLM позволяет обращаться к разным моделям через OpenAI-совместимый API.
- LLM формирует структурированный вывод по классам доменной модели; код PlantUML она не пишет.
- Доменная модель описывает архитектуру, функциональные требования и спецификацию API.
- Рендерер преобразует эту модель в диаграммы; его можно заменить или дополнить, например, Mermaid, без изменения доменной модели.

Повторная генерация при ошибках

1. LLM формирует структурированный ответ по классам доменной модели.
2. Ответ разбирается как JSON и преобразуется в типизированные модели.
3. При ошибке JSON-разбора в контекст добавляется описание ошибки.
4. Если модель не проходит доменные валидаторы, в контекст добавляется форматированное описание нарушенных правил.
5. LLM получает следующую попытку с учётом ошибки и исправляет ответ.

Число попыток ограничено настройкой. Если лимит исчерпан, генерация завершается ошибкой, а не запускается бесконечно.

Модель архитектуры C4

Типы узлов

- Клиент
- Балансировщик нагрузки
- Вычислительный узел
- База данных
- Кэш
- Брокер сообщений

Параметры узла

Фиксированные

- Характеристики и стоимость узлов Amazon EC2 по открытым источникам
- Каталог можно расширять конфигурациями других провайдеров и собственными узлами

Определяемые LLM

- Число реплик
- Параллелизм
- Время обработки
- Размер очереди

Профиль нагрузки (RPS) задаётся во входных данных.

Онтология связей между узлами

Пример разрешённых связей

- Клиент → вычислительный узел
- Вычислительный узел → база данных

Пример недопустимых связей

- Клиент → база данных
- База данных → вычислительный узел

Онтология задаёт допустимые пары типов узлов; проверка выполняется до построения диаграммы.

Протоколы взаимодействия между узлами

- LLM выбирает протокол для каждой связи в графе: HTTP (REST), gRPC, TCP или Message Queue.
- Выбор сохраняется в модели архитектуры и отражает способ обмена данными между узлами.
- Расчётные валидаторы учитывают протокол при оценке задержек и характеристик взаимодействия.
- При генерации диаграммы последовательностей протокол также определяет способ представления обмена сообщениями.

Планируется добавить: Webhooks, Long Polling, Server-Sent Events (SSE).

Реализованные валидаторы диаграммы компонентов

Структура графа

- У каждого узла уникальный идентификатор.
- Каждая связь соответствует разрешённой паре типов узлов.
- Граф не содержит циклов.
- Каждый узел связан хотя бы с одним другим узлом.

Реализованные валидаторы диаграммы компонентов

Валидация семантики

- Брокер сообщений должен быть связан с узлом-производителем и узлом-потребителем сообщений.
- При использовании кэша должен быть определён путь обращения к основному хранилищу при промахе кэша.

Валидация на основе расчётов

- Рассчитывается загрузка вычислительных узлов с учётом RPS, числа реплик и параллелизма.
- Оцениваются теоретическая задержка обработки и соблюдение заданного бюджета задержки.

Планируемые валидаторы диаграммы компонентов

Планируемые направления

- Симуляция нагрузки с помощью SimPy.
- Модели на основе теории массового обслуживания.
- Анализ очередей, задержек и насыщения под нагрузкой.

Цель: дополнить статические проверки оценкой поведения модели при заданном профиле нагрузки.

Реализованные валидаторы диаграммы последовательностей

Текущие правила

- На каждое функциональное требование — отдельная диаграмма.
- Ссылки на существующие роли и узлы C4.
- Соответствие сценария исходному требованию.
- Использование всех объявленных линий жизни.
- Разные бизнес-роли не используют один клиентский компонент.
- События и уведомления должны быть асинхронными.

Дальнейшее развитие

Расширение проверок семантики сообщений и ветвлений сценария.

REST API: OpenAPI и Swagger

OpenAPI 3.1

- Операции и маршруты
- Параметры и схемы
- Связь с требованиями и узлами C4

Проверки

- Уникальность операций
- Коллизии маршрутов
- Согласованность ссылок

Интерфейс и способы запуска

Текущая реализация

- Консольный интерфейс для запуска сценариев генерации и извлечения требований из текстовых документов; параметры генерации настраиваются.

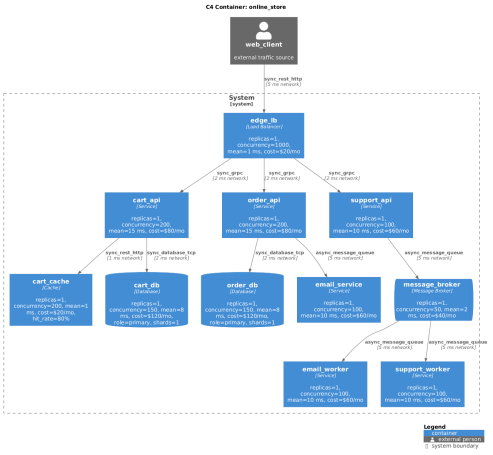
Возможные направления развития

- Добавить FastAPI, чтобы запускать инструмент как сервер и предоставлять его функции через API.
- Разработать отдельный фронтенд для настройки сценариев и просмотра результатов.

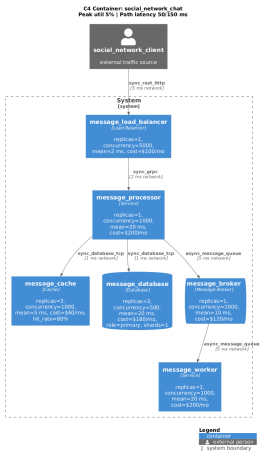
Дальнейшее развитие

- Расширить набор валидаторов архитектуры и сценариев.
- Добавить симуляционные и аналитические проверки нагрузки.
- Сохранить независимость модели от инструмента визуализации.

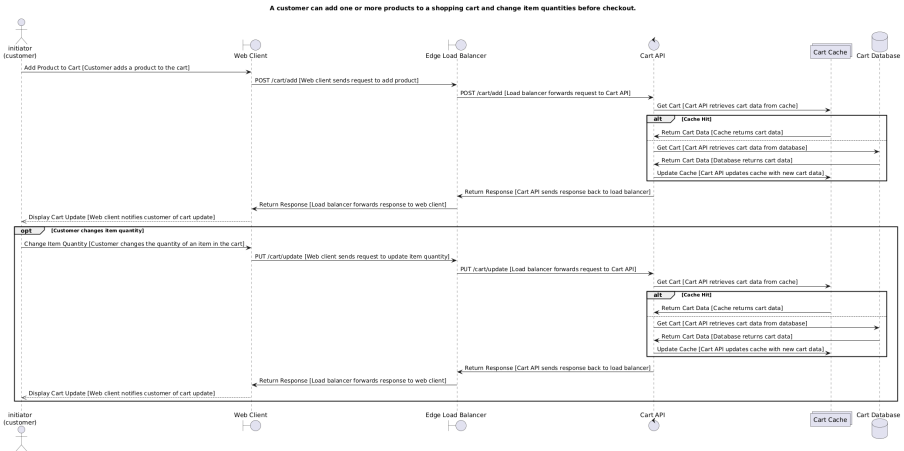
Пример C4-диаграммы 1



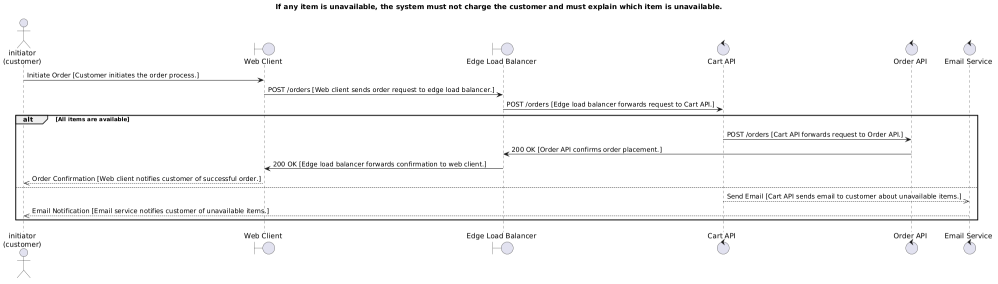
Пример C4-диаграммы 2



Пример диаграммы последовательностей 1



Пример диаграммы последовательностей 2



Пример спецификации Swagger

