Система автоматизации проектирования

архитектуры микросервисных систем

AutoSystemDesign

Дичковский Владимир

Цель

Разработать инструмент для автоматизированного построения и проверки архитектурных моделей микросервисной системы на основе функциональных и нефункциональных требований и заданного профиля нагрузки.

Входные данные и результаты

Пользователь передаёт на вход:

- BRD (документ бизнес-требований)
- Функциональные требования
- Нефункциональные требования
- Профиль нагрузки

Пользователь получает на выход:

- C4 Component Diagram
- Sequence-диаграмма на каждое функциональное требование
- OpenAPI 3.1 и Swagger UI

Вход можно задать в YAML или передать документ BRD: требования из документа извлекаются автоматически.

Извлечение требований из документа

Текст документа, например BRD

↓

LLM выделяет требования и приводит исходные фрагм

Цитаты показывают, на каком тексте основано каждое требо

↓

Программа проверяет цитаты по исходному докумен

↓

LLM сопоставляет проверенные требования с ожидаемыми полями доме

↓

YAML-сценарий + JSON-манифест

YAML-сценарий передаётся в существующий конвейер проектирования.

Проверка достоверности извлечённых данных

Правила проверки

- Каждая цитата должна присутствовать в исходном тексте.
- Значения полей сценария сопровождаются проверенными цитатами.
- Числа должны буквально встречаться в цитате: пересчёт единиц не выполняется.

Если подтверждения нет

- Неподтверждённые утверждения и значения исключаются с указанием причины.
- Неоднозначности и противоречия сохраняются для проверки человеком.

Сохраняется JSON-манифест с цитатами по полям и замечаниями.

Выходные артефакты

Диаграмма компонентов

- Скомпилированное изображение в выбранном формате (PNG/JPG)
- Исходный код PlantUML
- JSON доменной модели архитектуры компонентов

Диаграмма последовательностей

- Скомпилированное изображение в выбранном формате (PNG/JPG)
- Исходный код PlantUML
- JSON доменной модели диаграммы последовательно-стей

Спецификация API

- Спецификация OpenAPI в формате JSON
- Swagger UI в формате HTML

Изображения предназначены для просмотра, PlantUML — для редактирования диаграмм, JSON — для повторного использования структурированных моделей.

Варианты сервера рендеринга PlantUML

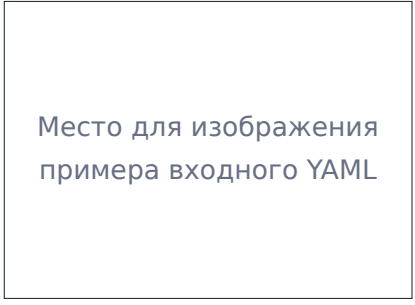
Для компиляции исходного кода PlantUML в изображение доступны три варианта:

1. **Локальный сервер PlantUML, развёртываемый через Docker Compose**
   Развёртывается вместе с проектом; конфигурация включена в репозиторий.
2. **Официальный сервер PlantUML**
   Используется размещённый разработчиками PlantUML сервер.
3. **Kroki**
   Универсальный сервис рендеринга диаграмм, поддерживающий PlantUML и другие форматы.

Пример входного YAML

Структура сценария

```yaml
project_name: "social_network_chat"
description: "Messaging module"
workload:
  baseline_requests_per_second: 500.0
  peak_requests_per_second: 2500.0
  read_ratio: 0.6
requirements:
  - type_identifier: latency
    threshold_value: 150.0
    percentile: 99.0
functional_requirements:
  - identifier: "req_msg_01"
    name: "Direct Message Delivery"
    text: >
      Sender sends a message to a recipient.
```



YAML — один из вариантов входа; требования также извлекаются из документа BRD.

Генерация и проверка

Требования и профиль нагрузки

↓

LLM через LiteLLM

Structured output по классам доменной модели

↓

Типизированные модели и валидаторы

↓

Генерация PlantUML и рендеринг

- LiteLLM позволяет обращаться к разным моделям через OpenAI-совместимый API.
- LLM формирует structured output по классам доменной модели; код PlantUML она не пишет.
- Доменная модель описывает архитектуру, функциональные требования и спецификацию API.
- Рендерер преобразует эту модель в диаграммы; его можно заменить

Модель архитектуры C4

Типы узлов

- Клиент
- Балансировщик нагрузки
- Вычислительный узел
- База данных
- Кэш
- Брокер сообщений

Параметры узла
Фиксированные

- Характеристики и стоимость узлов Amazon EC2 по открытым источникам
- Каталог можно расширять конфигурациями других провайдеров и собственными узлами

Определяемые LLM

- Число реплик
- Параллелизм
- Время обработки
- Размер очереди

Профиль нагрузки (RPS) задаётся во входных данных.

Онтология связей между узлами

Разрешённые связи

- Клиент → вычислительный узел
- Вычислительный узел → база данных

Запрещённые связи

- Клиент → база данных
- База данных → вычислительный узел

Онтология задаёт допустимые пары типов узлов; проверка выполняется до построения диаграммы.

Реализованные валидаторы диаграммы компонентов

Структура графа

- У каждого узла уникальный идентификатор.
- Каждая связь соответствует разрешённой паре типов узлов.
- Граф не содержит циклов.
- Каждый узел связан хотя бы с одним другим узлом.

Реализованные валидаторы диаграммы компонентов

Семантика взаимодействий

- Брокер сообщений связан с узлом-производителем и узлом-потребителем.
- Для кэша определён путь к основному хранилищу при промахе.

Расчётные проверки

- Загрузка вычислительных узлов с учётом RPS, числа реплик и параллелизма.
- Оценка задержки обработки и соблюдения заданного бюджета задержки.

Планируемые валидаторы диаграммы компонентов

Планируемые направления

- Симуляция нагрузки с помощью SimPy.
- Модели на основе теории массового обслуживания.
- Анализ очередей, задержек и насыщения под нагрузкой.

Цель: дополнить статические проверки оценкой поведения модели при заданном профиле нагрузки.

Реализованные валидаторы диаграммы последовательностей

Текущие правила

- На каждое функциональное требование — отдельная диаграмма.
- Ссылки на существующие роли и узлы C4.
- Соответствие сценария исходному требованию.
- Использование всех объявленных линий жизни.
- Разные бизнес-роли не используют один клиентский компонент.
- События и уведомления должны быть асинхронными.

Дальнейшее развитие

Расширение проверок семантики сообщений и ветвлений сценария.

REST API: OpenAPI и Swagger

OpenAPI 3.1

- Операции и маршруты
- Параметры и схемы
- Связь с требованиями и узлами C4

Проверки

- Уникальность операций
- Коллизии маршрутов
- Согласованность ссылок



Дальнейшее развитие

- Расширить набор валидаторов архитектуры и сценариев.
- Добавить симуляционные и аналитические проверки нагрузки.
- Сохранить независимость модели от инструмента визуализации.