Инструмент автоматизации проектирования

архитектуры микросервисных систем

AutoSystemDesign

Дичковский Владимир

Что делает AutoSystemDesign

Проектирование

- извлекает функциональные и нефункциональные требования из BRD;
- строит типизированную C4-модель компонентов;
- формирует Sequence-диаграмму для каждого требования;
- проектирует OpenAPI 3.1 и Swagger UI.

Проверка и анализ

- проверяет граф, связи, протоколы и трассировку требований;
- исправляет структурные ошибки в цикле повторной генерации;
- оценивает загрузку, задержки и критический путь;
- сохраняет редактируемые и машиночитаемые артефакты.

LLM предлагает модель; программные валидаторы определяют, можно ли передать её следующей стадии.

Единый пример: сервис заказов интернет-магазина

Функциональные требования

- **FR-001**: регистрация заказа по списку товаров с возвратом номера;
- **FR-002**: получение текущего статуса заказа по номеру.

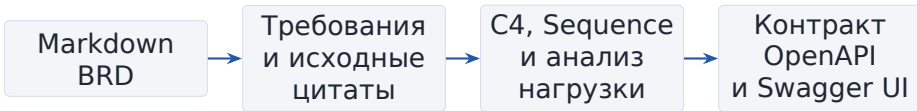
Граница примера

- оплата и управление складом не входят в систему;
- один BRD используется на всех следующих слайдах.

Нагрузка и ограничения

- 120 запросов/с обычно;
- 400 запросов/с в пике;
- 80% чтений, 20% записей;
- p95 ответа API $\leq$ 300 мс;
- бюджет $\leq$ 500 USD/месяц.

Вход и результат одного запуска



Что передаёт архитектор

- BRD с бизнес-требованиями;
- описание нагрузки и ограничений в том же документе.

Как используются результаты

- C4 и Sequence — обсуждение структуры и поведения системы;
- OpenAPI и Swagger — согласование API;
- отчёт нагрузки — поиск узких мест.

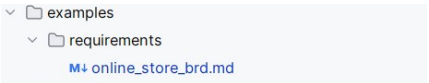
Минимальный запуск из BRD

```
uv run python scripts/generate_from_brd.py `
  --document examples/requirements/online_store_brd.md
```

- результат создаётся в `output/online_store_brd/`;
- одна команда запускает все стадии и сохраняет связанные результаты.

Входной BRD и созданные артефакты

Входной документ



Результаты генерации



Как BRD превращается в сценарий

BRD: требования, числа и ограничения

↓

LLM выделяет FR, NFR и точные исходные цитаты

↓

Программа сверяет цитаты с исходным документом

↓

Проверенные значения сопоставляются с типизированной моделью сценария

↓

Сценарий с подтверждёнными требованиями передаётся в конвейер

Проверка происхождения требований

Что сохраняется

- идентификатор требования;
- извлечённое значение;
- цитата из BRD;
- позиция и результат проверки.

Правила

- цитата должна буквально присутствовать в документе;
- числовое значение должно встречаться в подтверждающем фрагменте;
- неоднозначности остаются в diagnostics для просмотра человеком.

Зачем это архитектору: можно проследить, из какого места BRD возникли нагрузка, бюджет или функциональный сценарий, не перечитывая весь документ.

Архитектура конвейера генерации

C4
граф и параметры
→
Performance
поток и задержки
→
Sequence
сценарии FR
→
API
OpenAPI 3.1

LLM отвечает за предложение

- получает схему типизированной модели;
- формирует структурированный JSON;
- не пишет PlantUML напрямую.

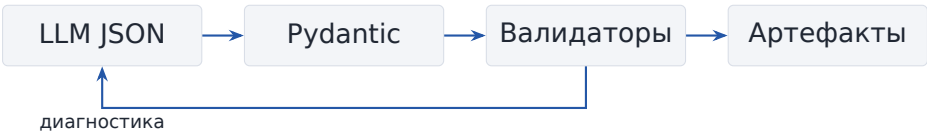
Код отвечает за контракт

- Pydantic разбирает результат;
- доменные спецификации проверяют правила;
- рендереры строят диаграммы, отчёт нагрузки и страницу просмотра API.

Стадии связаны типизированным контекстом: последующие артефакты используют проверенные результаты предыдущих.

Цикл исправления структурного ответа

1. LLM формирует JSON по схеме доменной модели.
2. Ответ разбирается и передаётся доменным валидаторам.
3. Ошибка JSON или нарушенное правило преобразуется в конкретную диагностику.
4. Диагностика добавляется в следующую попытку генерации.
5. После успешной проверки создаются артефакты; число попыток ограничено.



Доменная модель C4

Типы узлов

- клиент;
- балансировщик;
- сервис;
- база данных;
- кэш;
- брокер сообщений.

Параметры

- реплики;
- параллелизм;
- каналы обслуживания;
- время обработки;
- стоимость.

Связи

- REST/HTTP;
- gRPC;
- database TCP;
- message queue;
- вероятность и режим маршрутизации.

Эта модель одновременно служит источником для C4-диаграммы, расчёта производительности, Sequence и API.

Проверки C4 до построения диаграммы

Структура графа

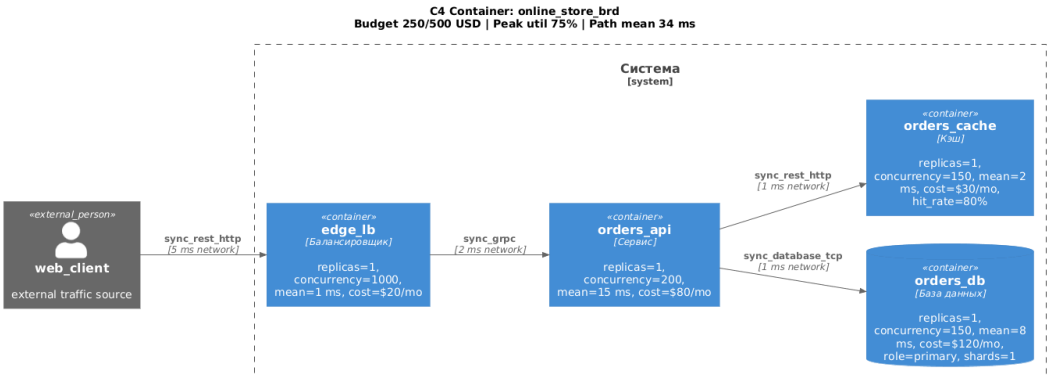
- уникальные идентификаторы узлов;
- существующие концы каждой связи;
- допустимая пара типов узлов;
- отсутствие циклов и изолированных узлов.

Архитектурная семантика

- кэш имеет путь к основному хранилищу;
- брокер связан с producer и consumer;
- протокол согласован с типами компонентов;
- параметры достаточны для расчёта нагрузки.

Онтология связей задаёт правила в промпте для LLM. Программные спецификации проверяют, соблюдает ли их сгенерированная модель.

C4-модель, полученная из BRD



Sequence-диаграммы связаны с C4

Правила генерации

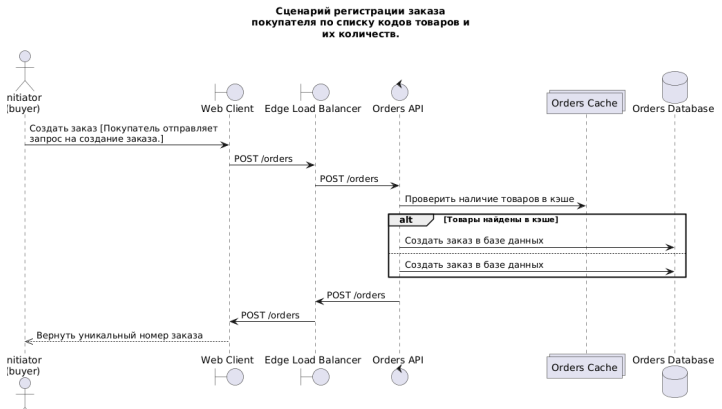
- отдельный сценарий на каждое FR;
- участники ссылаются на роли и узлы C4;
- переходы должны существовать в архитектурном графе;
- протокол влияет на вид сообщения;
- ветвления описываются типизированными блоками.

Проверки

- все объявленные линии жизни используются;
- инициатор и бизнес-роль согласованы;
- события и уведомления асинхронны;
- идентификатор требования сохраняется для API.

Sequence не является независимой картинкой: она проверяется относительно уже принятой C4-модели.

FR-001: регистрация заказа



Путь запроса: покупатель → Web Client → Edge Load Balancer → Orders API → cache/database.

Проектирование API из требований и Sequence

На вход стадии API

- FR-001 и FR-002;
- проверенные Sequence-сценарии;
- компоненты и точки входа C4.

На выходе

- дизайн операций и схем в JSON;
- спецификация OpenAPI 3.1;
- автономная страница Swagger UI.

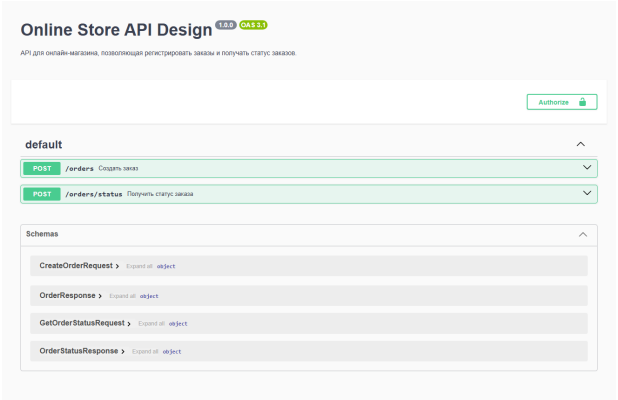
Фрагмент сгенерированного OpenAPI 3.1

```
"/orders": {
  "post": {
    "operationId": "create_order",
    "x-entrypoint-component": "edge_lb",
    "x-handler-component": "orders_api",
    "x-requirement-ids": ["FR-001"],
    "x-sequence-ids": ["SC-FR-001"],
    "responses": {"201": {...}}
  }
}
```

```
"/orders/status": {
  "post": {
    "operationId": "get_order_status",
    "x-entrypoint-component": "edge_lb",
    "x-handler-component": "orders_api",
    "x-requirement-ids": ["FR-002"],
    "x-sequence-ids": ["SC-FR-002"],
    "responses": {"200": {...}}
  }
}
```

Спецификация также содержит request/response schemas и ссылки `$ref` на компоненты OpenAPI.

Swagger UI из того же запуска



HTML открывается локально: операции `POST /orders` и `POST /orders/status`, а также четыре схемы данных.

Как рассчитывается производительность

Распространение потока

- пиковый RPS проходит по синхронным связям;
- ветви учитывают вероятность и routing mode;
- cache hit rate разделяет быстрый путь и обращение к БД.

Расчёт по узлам

- ёмкость = реплики × каналы / время обслуживания;
- вычисляются utilization, ожидание и средний ответ;
- самый длинный синхронный путь выделяется отдельно.

Критический путь (фрагмент сгенерированного PDF-отчёта)

Оценка средней задержки синхронного пути: **33,53 мс**



Загрузка компонентов (фрагмент сгенерированного PDF-отчёта)

Компонент	Нагрузка, запр./с	Пропускная способность, запр./с	Загрузка	Ожидание, мс	Ответ, мс
edge_lb	400.00	16 000.00	2.5%	0.00	1.00
orders_api	400.00	533.33	75.0%	1.53	16.53
orders_cache	400.00	4 000.00	10.0%	0.00	2.00
orders_db	80.00	2 000.00	4.0%	0.00	8.00